

Analyse et prévision de la série temporelle co2

Projet de séries temporelles

Table des matières

1	Objectif du projet	2
2	Chargement des bibliothèques et de la série	2
3	Découpage apprentissage/test	2
4	Analyse graphique de la série brute	3
5	Modèles de régression	4
5.1	Définition de la variable temps	4
5.2	Modèle 1 : tendance linéaire seule	4
5.3	Modèle 2 : tendance linéaire et effet mensuel	5
5.4	Modèle 3 : tendance et saisonnalité sinusoïdale	6
5.5	Modèle 4 : tendance et deux harmoniques saisonnières	7
5.6	Comparaison AIC des modèles de régression	8
6	Prévision par les modèles de régression	9
6.1	Construction de la variable temps pour le test	9
6.2	Prévision avec le modèle 4	9
6.3	Prévision avec le modèle 2	10
7	Modélisation SARIMA	11
7.1	Motivation	11
7.2	Transformation logarithmique	12
7.3	ACF et PACF de la série logarithmique	12
7.4	Différenciation ordinaire	13
7.5	Différenciation saisonnière	14
7.6	Test ADF	16
7.7	Modèles SARIMA candidats	16
7.8	Comparaison AIC des SARIMA	17
7.9	Modèle SARIMA automatique retenu dans le script	17
7.10	Diagnostic des résidus	18
7.11	Prévision sur l'échelle logarithmique	19
7.12	Retour à l'échelle originale	20
7.13	Erreurs de prévision du modèle SARIMA	20
8	Comparaison finale des modèles	21
9	Remarques critiques sur le choix du modèle optimal	21
10	Conclusion	22
	Script oral possible	22

1 Objectif du projet

Dans ce projet, on étudie la série temporelle `co2`, disponible directement dans R. Cette série contient des mesures mensuelles de concentration atmosphérique de dioxyde de carbone, exprimées en ppm. Comme il s'agit d'une série mensuelle, sa fréquence est égale à 12, ce qui signifie que l'on observe 12 valeurs par année.

L'objectif est double. D'abord, on cherche à comprendre la structure de la série : tendance, saisonnalité, stationnarité et autocorrélations. Ensuite, on construit des modèles de prévision afin d'estimer les valeurs de l'année 1997. Cette dernière année est conservée comme ensemble de test.

On compare deux grandes approches :

1. des modèles de régression avec tendance et saisonnalité ;
2. des modèles SARIMA, adaptés aux séries temporelles saisonnières.

2 Chargement des bibliothèques et de la série

Le code commence par charger les bibliothèques nécessaires :

```
library(forecast)
library(tseries)

data(co2)
```

La bibliothèque `forecast` fournit les fonctions utiles pour les modèles ARIMA/SARIMA, les prévisions, les ACF/PACF et les diagnostics. La bibliothèque `tseries` est utilisée ici principalement pour le test de stationnarité d'Augmented Dickey-Fuller, appelé avec la fonction `adf.test`.

La commande `data(co2)` charge la série `co2`. C'est un objet de type `ts`, donc R connaît automatiquement son index temporel et sa fréquence.

3 Découpage apprentissage/test

On sépare la série en deux parties :

```
train <- window(co2, end=c(1996,12))
test <- window(co2, start=c(1997,1))
```

La série `train` contient toutes les observations jusqu'à décembre 1996. La série `test` contient les observations de l'année 1997. Cette séparation est importante : en séries temporelles, on apprend un modèle sur le passé, puis on teste sa capacité à prévoir le futur.




FIGURE 1 – Séparation entre l'ensemble d'apprentissage et l'ensemble test.

Sur la Figure 1, la partie bleue correspond aux données d'entraînement, tandis que la partie rouge correspond à l'année 1997, utilisée pour tester les modèles.

4 Analyse graphique de la série brute

On visualise ensuite la série d'entraînement :

```
plot(train,
      main = "Série temporelle CO2",
      ylab = "ppm",
      xlab = "Temps",
      col = "darkgreen")
```




FIGURE 2 – Série temporelle CO2 sur l'ensemble d'apprentissage.

La Figure 2 montre deux phénomènes essentiels. Premièrement, la série présente une tendance croissante : la concentration de CO2 augmente globalement au cours du temps. Deuxièmement, on observe une saisonnalité annuelle : la série monte et descend de manière régulière chaque année.

La série brute n'est donc pas stationnaire. En effet, sa moyenne n'est pas constante dans le temps, puisqu'elle augmente progressivement. Elle possède aussi une structure saisonnière claire.

5 Modèles de régression

5.1 Définition de la variable temps

Dans le code, on définit :

```
t <- 1:length(train)
```

Ainsi, la variable t est un indice temporel mensuel :

$$t = 1, 2, 3, \dots, n.$$

Comme une année contient 12 mois, une saisonnalité annuelle doit s'écrire avec une période égale à 12. Par exemple :

$$\sin\left(\frac{2\pi t}{12}\right), \quad \cos\left(\frac{2\pi t}{12}\right).$$

5.2 Modèle 1 : tendance linéaire seule

Le premier modèle est :

```
modele1 <- lm(train ~ t)
```

Mathématiquement, il s'écrit :

$$CO2_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

Ce modèle capture seulement la tendance linéaire. Il suppose que le CO2 augmente en moyenne de façon régulière au cours du temps. Il ne tient pas compte de la saisonnalité.

Les principaux résultats obtenus sont :

Coefficient	Estimation	Interprétation
Intercept	3.116×10^2	niveau initial estimé
t	1.083×10^{-1}	augmentation moyenne mensuelle

TABLE 1 – Résumé simplifié du modèle 1.

La pente est très significative, avec une p-value inférieure à 2×10^{-16} . Le coefficient de détermination est $R^2 = 0.9677$, ce qui signifie que la tendance linéaire explique déjà une grande partie de la variabilité de la série. Cependant, ce bon R^2 ne doit pas faire oublier que le modèle ne reproduit pas les oscillations saisonnières.

5.3 Modèle 2 : tendance linéaire et effet mensuel

Le deuxième modèle ajoute une variable de mois :

```
mois <- factor(cycle(train))
modele2 <- lm(train ~ t + mois)
```

La commande `cycle(train)` renvoie le mois associé à chaque observation. Comme la série est mensuelle, les valeurs sont $1, 2, \dots, 12$. La fonction `factor` transforme ces valeurs en variable qualitative.

Le modèle s'écrit :

$$CO2_t = \beta_0 + \beta_1 t + \gamma_{m(t)} + \varepsilon_t,$$

où $m(t)$ désigne le mois correspondant à l'observation t .

La tendance linéaire modélise l'augmentation globale du CO2, tandis que les coefficients mensuels modélisent l'effet saisonnier de chaque mois.

Dans les sorties R, on obtient :

- une pente estimée à environ 0.1085 ppm par mois ;
- un écart-type résiduel égal à 1.625 ;
- un coefficient de détermination $R^2 = 0.9878$.

Ce modèle améliore donc nettement le modèle 1. La baisse de l'écart-type résiduel montre que la prise en compte de la saisonnalité réduit les erreurs d'ajustement.

Modèle avec tendance + saisonnalité




FIGURE 3 – Ajustement du modèle 2 : tendance linéaire et effet mensuel.

La Figure 3 montre que le modèle 2 suit bien les oscillations annuelles de la série.

5.4 Modèle 3 : tendance et saisonnalité sinusoïdale

Le troisième modèle remplace les effets mensuels par une saisonnalité trigonométrique :

```
modele3 <- lm(train ~ t +
               sin(2*pi*t/12) + cos(2*pi*t/12))
```

Mathématiquement :

$$CO2_t = \beta_0 + \beta_1 t + a \sin\left(\frac{2\pi t}{12}\right) + b \cos\left(\frac{2\pi t}{12}\right) + \varepsilon_t.$$

Les fonctions sinus et cosinus ont une période de 12 mois, car :

$$\sin\left(\frac{2\pi(t+12)}{12}\right) = \sin\left(\frac{2\pi t}{12} + 2\pi\right) = \sin\left(\frac{2\pi t}{12}\right).$$

Les résultats principaux sont :

Coefficient	Estimation	Signification
Intercept	3.115×10^2	niveau moyen initial
t	1.086×10^{-1}	tendance mensuelle
$\sin(2\pi t/12)$	2.199	composante saisonnière sinus
$\cos(2\pi t/12)$	-1.729	composante saisonnière cosinus

TABLE 2 – Résumé simplifié du modèle 3.

Les deux coefficients saisonniers sont très significatifs. Le modèle confirme donc l'existence d'une saisonnalité annuelle forte.

Le modèle 3 a un $R^2 = 0.9864$, légèrement inférieur à celui du modèle 2. Il est moins flexible que le modèle 2, car il impose une forme sinusoïdale régulière à la saisonnalité.

Modèle 3 : tendance + saisonnalité sinusoïdale




FIGURE 4 – Ajustement du modèle 3 : tendance et saisonnalité sinusoïdale annuelle.

5.5 Modèle 4 : tendance et deux harmoniques saisonnières

Le quatrième modèle enrichit le modèle 3 en ajoutant une deuxième harmonique :

```
modele4 <- lm(train ~ t +
  sin(2*pi*t/12) + cos(2*pi*t/12) +
  sin(4*pi*t/12) + cos(4*pi*t/12))
```

Il s'écrit :

$$CO2_t = \beta_0 + \beta_1 t + a_1 \sin\left(\frac{2\pi t}{12}\right) + b_1 \cos\left(\frac{2\pi t}{12}\right) + a_2 \sin\left(\frac{4\pi t}{12}\right) + b_2 \cos\left(\frac{4\pi t}{12}\right) + \varepsilon_t.$$

La première harmonique a une période de 12 mois. La deuxième harmonique vérifie :

$$\frac{4\pi t}{12} = \frac{2\pi t}{6},$$

donc elle a une période de 6 mois. Elle permet de rendre la forme saisonnière plus flexible.

Modèle 4 : tendance + saisonnalité sinusoïdale




FIGURE 5 – Ajustement du modèle 4 : tendance et deux harmoniques saisonnières.

Correction importante dans le code. Dans les sorties fournies, le résumé affiché pour le modèle 4 est en réalité encore celui du modèle 3, car le code contient :

```
print(summary(modele3))
```

Il faut corriger par :

```
print(summary(modele4))
```

L'AIC du modèle 4 est cependant bien calculé dans la table de comparaison, car l'objet `modele4` existe correctement.

5.6 Comparaison AIC des modèles de régression

Les AIC obtenus sont :

Modèle	Nombre de paramètres	AIC
Modèle 1	3	2172.481
Modèle 2	14	1751.733
Modèle 3	5	1784.032
Modèle 4	7	1739.348

TABLE 3 – Comparaison AIC des modèles de régression.

L'AIC le plus faible est celui du modèle 4. Selon ce critère, le modèle 4 est donc le meilleur compromis entre qualité d'ajustement et complexité parmi les quatre modèles de régression testés.

Le modèle 1 est clairement le moins bon, car il ignore la saisonnalité. Les modèles 2, 3 et 4 améliorent fortement l'ajustement. Le modèle 4 est meilleur que le modèle 3, car l'ajout de la deuxième harmonique permet de mieux représenter la forme saisonnière.

6 Prédiction par les modèles de régression

6.1 Construction de la variable temps pour le test

Comme on a défini :

$$t = 1, 2, \dots, n$$

sur l'ensemble d'apprentissage, il faut continuer l'indice temporel sur l'année 1997 :

```
t_test <- (length(train) + 1):(length(train) + length(test))
```

Cela garantit que les prédictions de 1997 correspondent bien aux mois qui suivent directement décembre 1996.

6.2 Prédiction avec le modèle 4

Le modèle 4 donne les erreurs suivantes sur l'année 1997 :

Indicateur	Valeur
RMSE	2.117759
MAPE	0.5682713%

TABLE 4 – Erreurs de prévision du modèle 4 sur 1997.

Prédiction vs Réalité (1997)




FIGURE 6 – Prévission du modèle 4 et valeurs réelles en 1997.

Le modèle 4 suit correctement la forme saisonnière, mais les erreurs restent autour de 2 ppm en RMSE.

6.3 Prévission avec le modèle 2

Pour le modèle 2, il faut aussi définir les mois de l'année test :

```
mois_test <- factor(cycle(test), levels = levels(mois))
```

L'argument `levels = levels(mois)` est important : il garantit que les modalités du facteur sont les mêmes dans le test que dans l'apprentissage.

Les erreurs obtenues sont :

Indicateur	Valeur
RMSE	2.107985
MAPE	0.5683844%

TABLE 5 – Erreurs de prévission du modèle 2 sur 1997.

Prédiction vs Réalité (1997)




FIGURE 7 – Préviation du modèle 2 et valeurs réelles en 1997.

Le modèle 2 et le modèle 4 ont des performances très proches sur l'année 1997. Le modèle 2 a un RMSE très légèrement plus faible, tandis que le modèle 4 a un MAPE très légèrement plus faible. La différence est faible ; on peut donc dire que les deux modèles de régression donnent des prévisions comparables sur l'année test.

7 Modélisation SARIMA

7.1 Motivation

Les modèles de régression capturent la tendance et la saisonnalité, mais ils ne modélisent pas explicitement la dépendance temporelle entre les erreurs. En série temporelle, les erreurs successives peuvent être corrélées. Les modèles SARIMA sont conçus pour prendre en compte cette dépendance.

Un modèle SARIMA s'écrit :

$$SARIMA(p, d, q)(P, D, Q)_s,$$

où :

- p est l'ordre autorégressif non saisonnier ;
- d est le nombre de différenciations ordinaires ;
- q est l'ordre moyenne mobile non saisonnier ;
- P est l'ordre autorégressif saisonnier ;
- D est le nombre de différenciations saisonnières ;
- Q est l'ordre moyenne mobile saisonnier ;

— s est la période saisonnière.

Ici, la série est mensuelle, donc $s = 12$.

7.2 Transformation logarithmique

Le code utilise :

```
log_train <- log(train)
log_test  <- log(test)
```

Le logarithme est optionnel pour la série CO2, car la variance ne semble pas augmenter aussi fortement que dans la série **AirPassengers**. Cependant, il est acceptable. Il permet de travailler sur une échelle relative et de stabiliser légèrement la série.

Logarithme de la série CO2 – données d'entraînement




FIGURE 8 – Logarithme de la série CO2 sur l'ensemble d'apprentissage.


La série logarithmique garde une tendance croissante et une saisonnalité annuelle. Le logarithme ne suffit donc pas à rendre la série stationnaire.

7.3 ACF et PACF de la série logarithmique

L'ACF mesure la corrélation entre Y_t et Y_{t-h} . Elle est définie par :

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)},$$

où $\gamma(h)$ est l'autocovariance au retard h .



(a) ACF de $\log(CO_2)$.

(b) PACF de $\log(CO_2)$.

FIGURE 9 – ACF et PACF de la série logarithmique.

L'ACF décroît lentement et reste élevée sur de nombreux retards. Cela confirme que la série n'est pas stationnaire. Une série stationnaire aurait généralement une ACF qui revient plus rapidement vers zéro.

7.4 Différenciation ordinaire

On applique une différenciation ordinaire :

```
d1_log_train <- diff(log_train, differences = 1)
```

Cela correspond à :

$$\nabla Y_t = Y_t - Y_{t-1}.$$

La différenciation ordinaire sert principalement à retirer la tendance.





FIGURE 10 – Différenciation ordinaire de $\log(\text{CO}_2)$.

La série différenciée est beaucoup plus centrée autour de zéro. Cependant, les ACF/PACF montrent encore une structure saisonnière, notamment aux retards proches des multiples de 12.



(a) ACF après différenciation ordinaire.

(b) PACF après différenciation ordinaire.

FIGURE 11 – ACF et PACF après différenciation ordinaire.

7.5 Différenciation saisonnière

Comme il reste une saisonnalité annuelle, on applique une différenciation saisonnière de période 12 :

```
d2_log_train <- diff(d1_log_train, lag = 12)
```

Cela correspond à :

$$\nabla_{12}\nabla Y_t = (Y_t - Y_{t-1}) - (Y_{t-12} - Y_{t-13}).$$

On a donc appliqué :

$$d = 1, \quad D = 1.$$

Différenciation ordinaire + saisonnière





FIGURE 12 – Série après différenciation ordinaire et saisonnière.

La série obtenue est beaucoup plus proche d'une série stationnaire : elle oscille autour de zéro sans tendance visible.



(a) ACF après double différenciation.

(b) PACF après double différenciation.

FIGURE 13 – ACF et PACF après double différenciation.

Après double différenciation, les autocorrélations sont nettement plus faibles. On peut alors chercher un modèle de la forme :

$$SARIMA(p, 1, q)(P, 1, Q)_{12}.$$

7.6 Test ADF

Le test d'Augmented Dickey-Fuller est utilisé pour tester la stationnarité. Son hypothèse nulle est :

$$H_0 : \text{la série est non stationnaire.}$$

Les résultats obtenus sont :

Série testée	Statistique ADF	p-value
$\log(CO_2)$	-3.1918	0.08941
Série doublement différenciée	-9.0433	0.01

TABLE 6 – Résultats du test ADF.

Pour $\log(CO_2)$, la p-value vaut 0.08941, donc elle est supérieure à 0.05. On ne rejette pas l'hypothèse de non-stationnarité. Cela confirme que la série brute logarithmique n'est pas stationnaire.

Après différenciation ordinaire et saisonnière, la p-value affichée est 0.01, avec un avertissement indiquant qu'elle est en fait plus petite que la valeur imprimée. On rejette donc l'hypothèse de non-stationnarité. Cela confirme que la série transformée est devenue stationnaire.

7.7 Modèles SARIMA candidats

On ajuste plusieurs modèles :

```
mod_sarima_1 <- Arima(log_train,
                      order = c(0, 1, 1),
                      seasonal = list(order = c(0, 1, 1), period = 12))

mod_sarima_2 <- Arima(log_train,
                      order = c(1, 1, 1),
```

```

seasonal = list(order = c(0, 1, 1), period = 12))

mod_sarima_3 <- Arima(log_train,
                     order = c(0, 1, 1),
                     seasonal = list(order = c(1, 1, 1), period = 12))

mod_sarima_4 <- Arima(log_train,
                     order = c(1, 1, 0),
                     seasonal = list(order = c(0, 1, 1), period = 12))

mod_sarima_auto <- auto.arima(log_train,
                             seasonal = TRUE,
                             stepwise = FALSE,
                             approximation = FALSE)

```

La fonction `auto.arima` recherche automatiquement un modèle adapté. Les options `stepwise = FALSE` et `approximation = FALSE` rendent la recherche plus complète et plus précise.

7.8 Comparaison AIC des SARIMA

Les AIC obtenus sont :

Modèle	Nombre de paramètres	AIC
SARIMA(0,1,1)(0,1,1) ₁₂	3	-5003.095
SARIMA(1,1,1)(0,1,1) ₁₂	4	-5003.096
SARIMA(0,1,1)(1,1,1) ₁₂	4	-5001.676
SARIMA(1,1,0)(0,1,1) ₁₂	3	-4997.073
Auto ARIMA	6	-5001.899

TABLE 7 – Comparaison AIC des modèles SARIMA.

Un point important apparaît ici : le modèle automatique n'a pas le plus petit AIC dans ce tableau. Le plus petit AIC est celui du modèle SARIMA(1,1,1)(0,1,1)₁₂, avec $AIC = -5003.096$. Il est cependant quasiment identique à celui du modèle SARIMA(0,1,1)(0,1,1)₁₂, qui vaut -5003.095 .

Dans le code fourni, le modèle retenu est :

```
meilleur_modele <- mod_sarima_auto
```

Ce choix est défendable si l'on souhaite utiliser le modèle choisi automatiquement par R et si ses diagnostics sont bons. Mais si l'on suit strictement le critère AIC dans la table ci-dessus, il faudrait plutôt choisir `mod_sarima_2`. Pour être parfaitement rigoureux, on devrait comparer aussi les erreurs de prévision sur l'année 1997 pour tous les modèles SARIMA candidats.

Dans la suite de ce rapport, on commente les résultats obtenus avec le modèle effectivement utilisé dans le script, c'est-à-dire le modèle automatique.

7.9 Modèle SARIMA automatique retenu dans le script

Le résumé du modèle automatique est :

```
ARIMA(0,1,1)(2,1,2)[12]
```

Les coefficients estimés sont :

Coefficient	Estimation	Erreur standard
ma1	-0.3557	0.0501
sar1	0.8654	0.1427
sar2	-0.1045	0.0563
sma1	-1.7569	0.1387
sma2	0.7868	0.1269

TABLE 8 – Coefficients du modèle ARIMA(0,1,1)(2,1,2)₁₂.

Ce modèle contient :

- une différenciation ordinaire : $d = 1$;
- une différenciation saisonnière : $D = 1$;
- un terme moyenne mobile non saisonnier : $q = 1$;
- deux termes autorégressifs saisonniers : $P = 2$;
- deux termes moyenne mobile saisonniers : $Q = 2$;
- une période saisonnière 12.

L'écart-type estimé de l'erreur est faible, avec $\sigma^2 = 1.666 \times 10^{-6}$ sur l'échelle logarithmique.

7.10 Diagnostic des résidus

La fonction `checkresiduals` produit un diagnostic graphique et le test de Ljung-Box.




FIGURE 14 – Diagnostic des résidus du modèle ARIMA(0,1,1)(2,1,2)₁₂.

Un bon modèle SARIMA doit laisser des résidus proches d'un bruit blanc. Cela signifie que les résidus doivent être centrés autour de zéro et ne plus présenter d'autocorrélation significative. Le test de Ljung-Box donne :

$$Q^* = 23.487, \quad df = 19, \quad p\text{-value} = 0.2166.$$

L'hypothèse nulle du test est :

H_0 : les résidus ne sont pas autocorrélés.

Comme la p-value vaut 0.2166, elle est supérieure à 0.05. On ne rejette donc pas l'hypothèse nulle. Cela signifie qu'il ne reste pas d'autocorrélation significative dans les résidus. Le modèle a donc capturé l'essentiel de la structure temporelle de la série.

On observe néanmoins un résidu extrême au début de la série. Il peut être lié aux effets d'initialisation et aux différenciations. Il ne remet pas nécessairement en cause le modèle, mais il faut le mentionner avec prudence.

7.11 Prédiction sur l'échelle logarithmique

Le modèle est ajusté sur `log_train`. La prédiction est donc d'abord obtenue sur l'échelle logarithmique :

```
pred_log <- forecast(meilleur_modele, h = length(test))
```




FIGURE 15 – Prédiction SARIMA sur l'échelle logarithmique.

La prédiction prolonge la tendance et la saisonnalité observées sur les données d'apprentissage.

7.12 Retour à l'échelle originale

Comme le modèle a été construit sur $\log(CO_2)$, on revient à l'échelle originale avec l'exponentielle :

```
pred_co2 <- exp(pred_log$mean)
```

Autrement dit :

$$\widehat{CO_2}_t = \exp\left(\log(\widehat{CO_2}_t)\right).$$




FIGURE 16 – Prévision SARIMA sur l'échelle originale pour l'année 1997.

Sur la Figure 17, les prévisions SARIMA sont très proches des valeurs observées de 1997. Les deux courbes sont presque superposées.

7.13 Erreurs de prévision du modèle SARIMA

Les erreurs obtenues sur l'année 1997 sont :

Indicateur	Valeur
RMSE	0.5239398
MAE	0.4535337
MAPE	0.1246279%

TABLE 9 – Erreurs de prévision du modèle SARIMA sur 1997.

Le RMSE vaut environ 0.524 ppm, ce qui est beaucoup plus faible que les RMSE des modèles de régression. Le MAPE vaut environ 0.125%, ce qui indique une erreur relative moyenne très faible.

8 Comparaison finale des modèles

On peut comparer les trois modèles principaux :

Modèle	RMSE	MAE	MAPE
Régression modèle 2	2.107985	non calculé dans le code	0.5683844%
Régression modèle 4	2.117759	non calculé dans le code	0.5682713%
SARIMA automatique	0.5239398	0.4535337	0.1246279%

TABLE 10 – Comparaison des performances de prévision sur 1997.

Le modèle SARIMA est nettement meilleur en prévision sur l'année 1997. Son RMSE est environ quatre fois plus faible que celui des modèles de régression. Cela montre que la prise en compte de la dépendance temporelle apporte une amélioration importante.

Les modèles de régression capturent la tendance et la saisonnalité de manière déterministe. Le SARIMA, lui, capture aussi la structure temporelle résiduelle grâce aux termes AR et MA. C'est pourquoi il est plus performant ici.

9 Remarques critiques sur le choix du modèle optimal

Il faut être rigoureux sur la notion d'optimalité. On ne peut pas affirmer qu'un modèle SARIMA est optimal au sens absolu. On peut seulement dire qu'il est meilleur selon certains critères et parmi les modèles testés.

Dans les sorties obtenues, le modèle automatique utilisé pour la prévision est :

$$ARIMA(0, 1, 1)(2, 1, 2)_{12}.$$

Ses diagnostics sont bons et ses erreurs de prévision sont faibles. Cependant, le tableau AIC montre que `mod_sarima_2`, c'est-à-dire

$$SARIMA(1, 1, 1)(0, 1, 1)_{12},$$

a un AIC très légèrement plus faible.

Pour une conclusion parfaitement rigoureuse, il faudrait donc comparer les erreurs de prévision de tous les modèles SARIMA candidats sur l'année 1997. Le meilleur modèle final serait celui qui combine :

1. un AIC faible ;
2. des résidus proches d'un bruit blanc ;
3. un RMSE, MAE ou MAPE faible sur l'ensemble test.

La phrase correcte à utiliser est donc :

Le modèle retenu n'est pas optimal au sens absolu, mais il constitue un très bon compromis parmi les modèles testés, car il donne des résidus proches d'un bruit blanc et une très bonne prévision sur l'année 1997.

10 Conclusion

L'étude de la série `co2` montre une tendance croissante nette et une saisonnalité annuelle marquée. Les modèles de régression permettent de modéliser cette structure de manière simple. Le modèle linéaire seul est insuffisant, car il ignore la saisonnalité. L'ajout d'effets mensuels ou de composantes trigonométriques améliore fortement l'ajustement.

Dans un second temps, une approche SARIMA est utilisée. L'analyse de l'ACF et de la PACF de $\log(CO_2)$ montre que la série n'est pas stationnaire. Une différenciation ordinaire est appliquée pour retirer la tendance, puis une différenciation saisonnière de période 12 est appliquée pour retirer la saisonnalité annuelle. Après cette transformation, la série est beaucoup plus proche d'une série stationnaire.

Le modèle SARIMA automatique utilisé dans le script est un $ARIMA(0,1,1)(2,1,2)_{12}$. Le test de Ljung-Box appliqué aux résidus donne une p-value de 0.2166, ce qui indique qu'il ne reste pas d'autocorrélation significative dans les résidus. Le modèle capture donc correctement la structure temporelle de la série.

Enfin, la prévision sur l'année 1997 est très précise : le RMSE est d'environ 0.524 ppm et le MAPE d'environ 0.125%. Le modèle SARIMA est donc nettement meilleur que les modèles de régression pour la prévision sur cette année test.

Script oral possible

Voici une version orale possible :

Dans ce projet, nous avons étudié la série mensuelle CO_2 disponible dans R. L'objectif était de modéliser son évolution et de prévoir l'année 1997. Nous avons donc séparé la série en un ensemble d'apprentissage jusqu'à décembre 1996 et un ensemble de test correspondant à l'année 1997.

La première visualisation montre une tendance croissante très nette ainsi qu'une saisonnalité annuelle. Nous avons d'abord utilisé des modèles de régression. Le premier modèle contient seulement une tendance linéaire ; il explique une grande partie de la variabilité, mais il ne reproduit pas les oscillations saisonnières. Nous avons donc ajouté une saisonnalité, soit avec des effets mensuels, soit avec des fonctions sinus et cosinus. Le modèle avec deux harmoniques obtient le meilleur AIC parmi les modèles de régression.

Ensuite, nous avons utilisé une approche SARIMA. Comme la série est mensuelle, la période saisonnière est 12. Nous avons travaillé sur le logarithme de la série, puis étudié l'ACF et la PACF. La série brute n'est pas stationnaire, donc nous avons appliqué une différenciation ordinaire pour réduire la tendance, puis une différenciation saisonnière pour supprimer la saisonnalité annuelle.

Après cette double différenciation, la série est beaucoup plus stable autour de zéro. Nous avons alors ajusté plusieurs modèles SARIMA. Le modèle automatique utilisé dans le script est un $ARIMA(0,1,1)(2,1,2)$ de période 12. Ses résidus sont globalement compatibles avec un bruit blanc, car le test de Ljung-Box donne une p-value supérieure à 0.05.

Enfin, la prévision de 1997 est très proche des valeurs observées. Le RMSE du modèle SARIMA est environ 0.52 ppm, contre environ 2.1 ppm pour les modèles de régression. Le SARIMA donne donc la meilleure performance de prévision dans notre étude.

A Code R corrigé conseillé

Voici les deux petites corrections principales à faire dans le script :

```
# Correction du résumé du modèle 4
print(summary(modele4))
```

et, si l'on veut suivre strictement le plus petit AIC SARIMA obtenu dans la table :

```
# Si l'on choisit strictement selon l'AIC du tableau
meilleur_modele <- mod_sarima_2
```

Sinon, on peut garder le modèle automatique, mais il faut expliquer qu'il est choisi comme modèle final car ses diagnostics et ses erreurs de prévision sont bons, et non parce qu'il minimise strictement l'AIC dans la table affichée.

Pour comparer proprement tous les modèles SARIMA sur l'année 1997, on peut ajouter :

```
modeles_sarima <- list(
  "SARIMA(0,1,1)(0,1,1)[12]" = mod_sarima_1,
  "SARIMA(1,1,1)(0,1,1)[12]" = mod_sarima_2,
  "SARIMA(0,1,1)(1,1,1)[12]" = mod_sarima_3,
  "SARIMA(1,1,0)(0,1,1)[12]" = mod_sarima_4,
  "SARIMA automatique" = mod_sarima_auto
)

scores_prevision <- function(model, test) {
  pred <- forecast(model, h = length(test))
  pred_co2 <- exp(pred$mean)
  erreur <- as.numeric(test) - as.numeric(pred_co2)
  RMSE <- sqrt(mean(erreur^2))
  MAE <- mean(abs(erreur))
  MAPE <- mean(abs(erreur / as.numeric(test))) * 100
  return(c(RMSE = RMSE, MAE = MAE, MAPE = MAPE))
}

comparaison_test <- t(sapply(modeles_sarima,
                             scores_prevision,
                             test = test))
print(comparaison_test)
```

Ce tableau permettrait de choisir le modèle final non seulement à partir de l'AIC, mais aussi à partir de la qualité de prévision réelle sur l'année 1997.